KHUNG SƯỜN LÝ THUYẾT NGHIÊN CỨU KHOA HỌC

Mô hình MS-GARCH-X với phân phối sai số Student-t cho hợp đồng tương lai VN30F1M

Nguyễn Hoài Nam, Nguyễn Thuận Hiếu, Đặng Chí Hiếu

Tháng 9 năm 2026

Bảng ký hiệu

Ký hiệu	Ý nghĩa
r_t	Lợi suất logarit theo phần trăm tại phiên t.
ε_t	Nhiễu của phương trình trung bình.
z_t	Sai số chuẩn hóa, $\mathbb{E}[z_t] = 0$ và $\mathrm{Var}(z_t) = 1$.
$h_{t,s}$	Phương sai có điều kiện tại t khi $S_t = s$.
$\bar{\mu}_{t-1},\ \bar{h}_{t-1}$	Trung bình và phương sai hỗn hợp thu gọn tại $t-1$.
$\bar{\varepsilon}_{t-1}$	Phần dư thu gọn, $\bar{\varepsilon}_{t-1} = r_{t-1} - \bar{\mu}_{t-1}$.
S_t	Trạng thái ẩn, $S_t \in \{1, 2\}$.
p_{ij}	Xác suất chuyển từ trạng thái i sang j.
$\mathbf{P}$	Ma trận chuyển trạng thái Markov.
$\xi_{t\|u}(s)$	Xác suất $S_t = s$ có điều kiện trên thông tin đến u.
$\pi_s,\ d_s$	Xác suất dừng và thời gian tồn tại kỳ vọng của trạng thái s.
$\mu_s, \omega_s, \alpha_s, \beta_s$	Hệ số trung bình và phương sai của trạng thái s.
$\boldsymbol{\gamma}_s$	Vector hệ số biến ngoại sinh của trạng thái s.
θ_s	Hệ số đòn bẩy (hiệu ứng dấu) của trạng thái s trong đặc tả EGARCH.
$\mathbf{X}_{t-1}$	Vector k biến ngoại sinh, biết trước thời điểm dự báo.
ν	Bậc tự do của phân phối Student-t chuẩn hóa.
t_ν^*	Phân phối Student-t chuẩn hóa về phương sai đơn vị.
$\boldsymbol{\theta}$	Vector toàn bộ tham số liên tục của mô hình.
$\boldsymbol{\phi}$	Ảnh của $\boldsymbol{\theta}$ trên không gian không ràng buộc $\mathbb{R}^d$.
$\mathcal{F}_{t-1}$	Tập thông tin đến cuối phiên $t-1$.
$\mathcal{D}_T$	Toàn bộ dữ liệu dùng cho suy diễn đến T.
$\mathcal{L}(\boldsymbol{\theta}; \mathcal{D}_T)$	Hàm likelihood của mẫu huấn luyện.
$\ell_T(\boldsymbol{\theta})$	Hàm log-likelihood, $\ell_T = \ln \mathcal{L}$.
$p(\boldsymbol{\theta}),\ p(\boldsymbol{\theta} \mid \mathcal{D}_T)$	Mật độ tiên nghiệm và hậu nghiệm.
$q(\boldsymbol{\phi})$	Phân phối xấp xỉ hậu nghiệm trong suy diễn biến phân.
diag(·)	Ma trận đường chéo tạo từ các phần tử trong ngoặc.
vech(·)	Vector hóa phần tam giác dưới của một ma trận.
RV_t	Biến động thực tế, đo trên thang phương sai.
$\mathrm{VaR}_{t,\alpha}$	Giá trị chịu rủi ro tại mức xác suất đuôi α.

1 Dữ liệu

1.1 Nguồn dữ liệu và xây dựng chuỗi

Dữ liệu là chuỗi giá trong ngày của hợp đồng tương lai chỉ số VN30 kỳ hạn gần nhất (VN30F1M), giai đoạn từ ngày 07/11/2017 đến ngày 17/07/2026. Chuỗi lợi suất logarit theo phần trăm được xác định bởi

$$r_t = 100 \times \ln(P_t / P_{t-1}), \tag{1.1}$$

trong đó P_t là giá đóng cửa phiên t. Sau khi làm sạch và loại phiên đầu tiên (không xác định được lợi suất), mẫu gồm 2170 quan sát ngày.

Đại lượng đại diện cho biến động thực tế được xây dựng từ lợi suất trong ngày:

$$RV_t = \sum_{m=1}^{M_t} r_{t,m}^2 \tag{1.2}$$

với $r_{t,m}$ là lợi suất logarit của thanh giá thứ m trong phiên t và M_t là số thanh giá của phiên đó. Vì (1.2) là tổng bình phương, RV_t nằm trên *thang phương sai*, cùng đơn vị với $h_{t,s}$; sự thống nhất đơn vị này là điều kiện để các hàm tổn thất ở Mục 5 có nghĩa.

Vector biến ngoại sinh gồm $k = 2$ thành phần, đều trễ một bậc để bảo đảm khả dụng tại thời điểm lập dự báo:

$$\mathbf{X}_{t-1} = \left(\ln(1 + V_{t-1}),\ \ln(RV_{t-1} + \epsilon) \right)^{\top}, \tag{1.3}$$

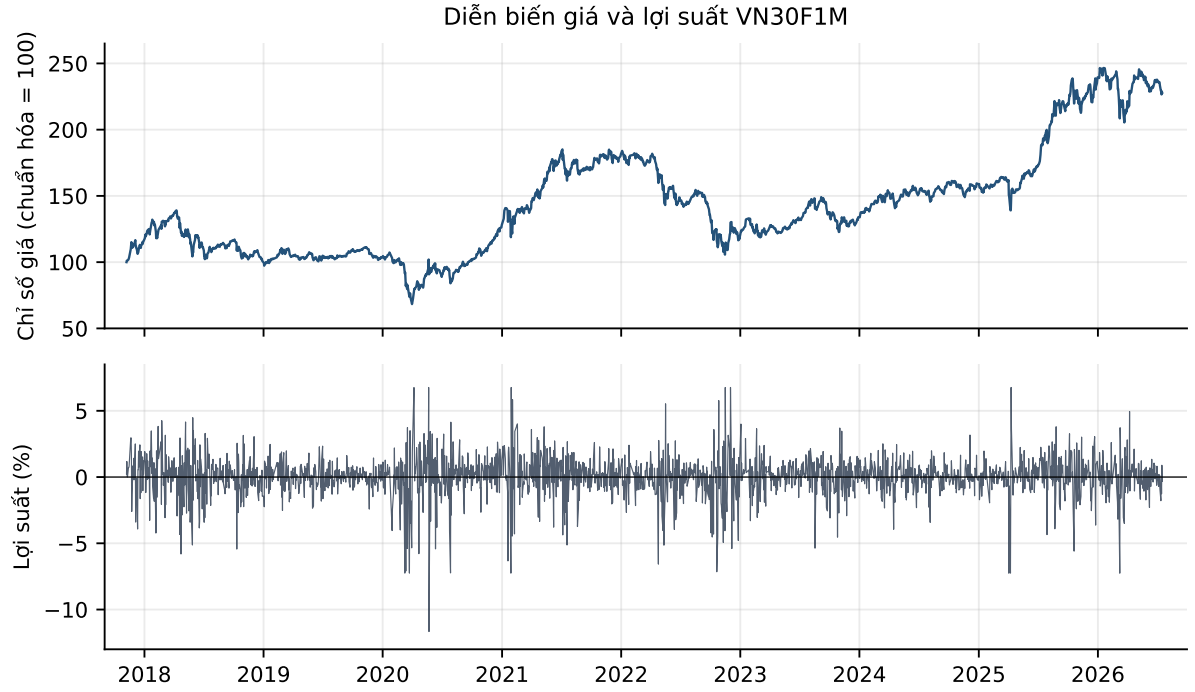
với V_{t-1} là khối lượng giao dịch và $\epsilon > 0$ là hằng số nhỏ tránh logarit của không. Phép biến đổi logarit làm giảm độ lệch phải rất mạnh của hai đại lượng gốc. Cả hai thành phần được chuẩn hóa z-score bằng trung bình và độ lệch chuẩn *của riêng tập huấn luyện*; dùng thống kê toàn mẫu sẽ đưa thông tin của giai đoạn kiểm định vào giai đoạn huấn luyện và làm mọi kết quả ngoài mẫu mất hiệu lực.

1.2 Thống kê mô tả

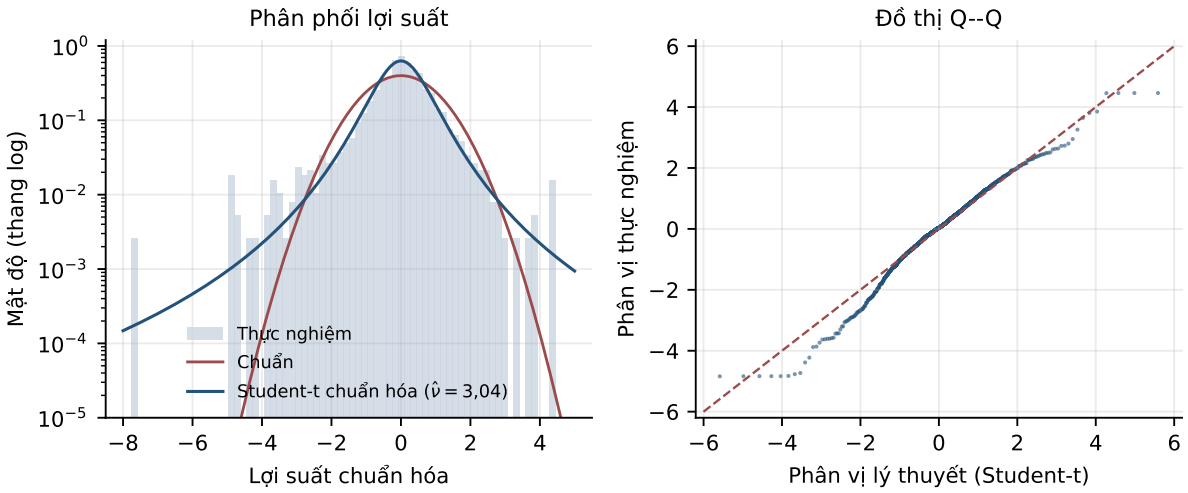
Bảng 2: Thống kê mô tả của lợi suất, biến động thực tế và biến ngoại sinh

Chuỗi	Số quan sát	Trung bình	Độ lệch chuẩn	Skewness	Kurtosis	Giá trị nhỏ nhất	Giá trị lớn nhất
r_t	2170	0,0381	1,5070	−0,829	9,026	−11,6612	6,7631
RV_t	2170	1,3275	2,3474	7,195	86,957	0,0304	43,2472
X_1: Khối lượng	2170	0,1285	0,9500	−1,444	5,764	−4,0025	2,0458
X_2: RV trễ	2170	−0,0170	0,9666	0,484	3,180	−2,9491	3,8108

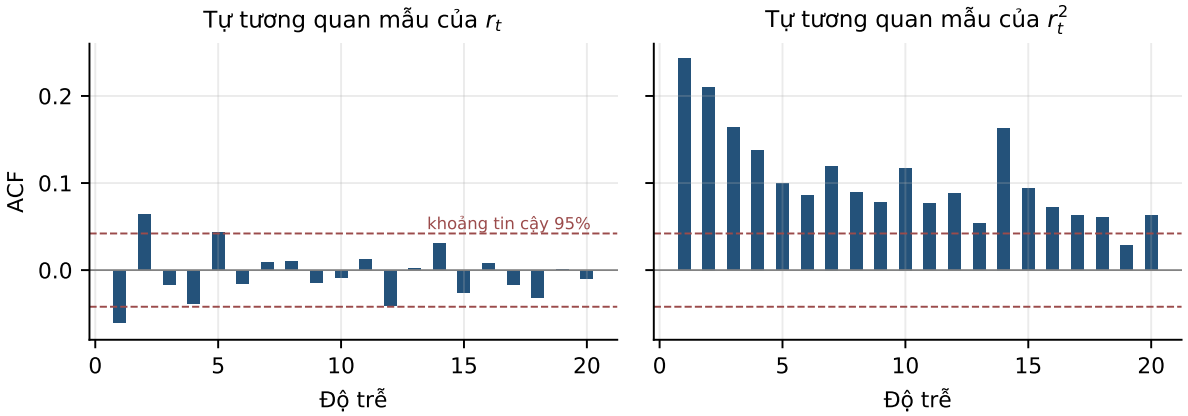
Ghi chú: Lợi suất tính theo phần trăm. Độ lệch chuẩn dùng ước lượng mẫu với bậc tự do $n - 1$; skewness và kurtosis chuẩn hóa theo cùng độ lệch chuẩn đó. Hai biến ngoại sinh đã chuẩn hóa z-score theo thống kê tập huấn luyện, nên trung bình của chúng trên toàn mẫu không bằng đúng không.



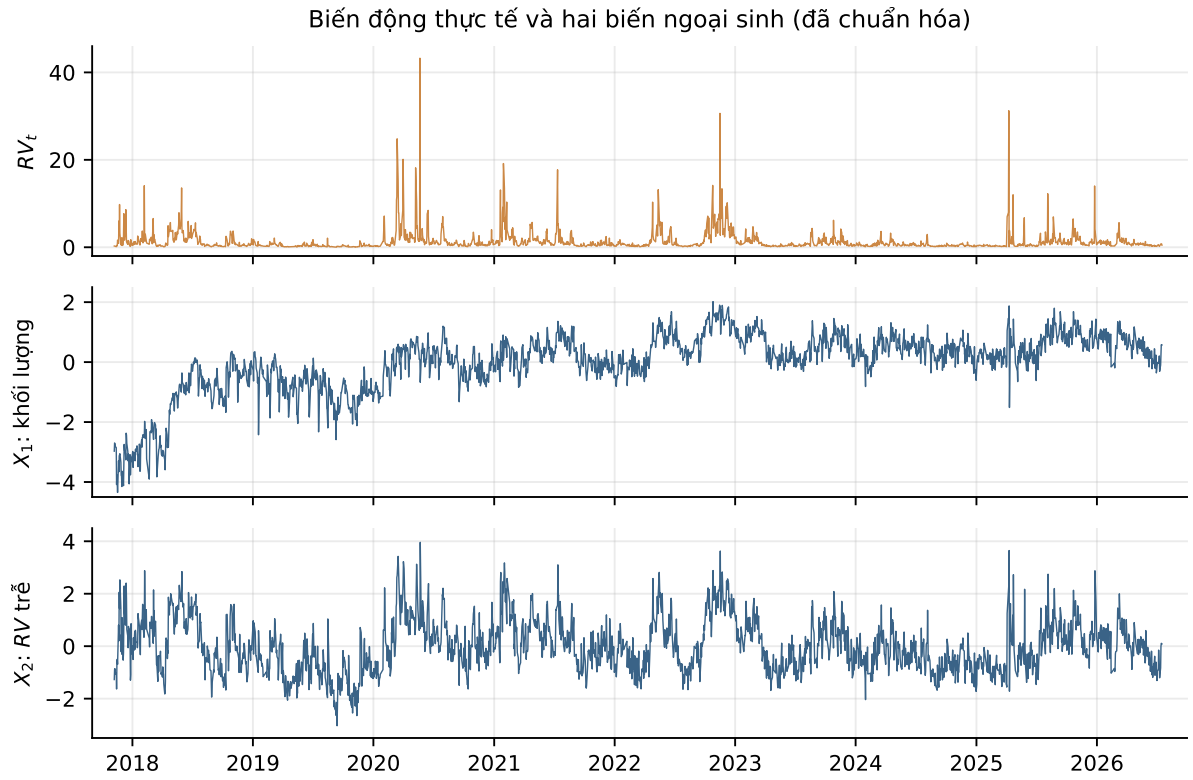
Hình 1: Diễn biến giá đóng cửa và chuỗi lợi suất logarit VN30F1M giai đoạn 2017–2026 trên toàn bộ mẫu dữ liệu (2170 quan sát ngày).



Hình 2: Phân phối lợi suất chuẩn hóa (thang logarit) và đồ thị Q–Q so với Student-t chuẩn hóa.



Hình 3: Tự tương quan mẫu của r_t và r_t^2, kèm khoảng tin cậy 95%.



Hình 4: Biến động thực tế RV_t và hai biến ngoại sinh sau chuẩn hóa.

2 Đặc tả mô hình

2.1 Phân phối sai số

Mọi mô hình viết dưới dạng $r_t = \mu_{(\cdot)} + \varepsilon_t$ với $\varepsilon_t = \sqrt{h_{t,(\cdot)}}\, z_t$ và z_t độc lập cùng phân phối, chuẩn hóa sao cho $\mathbb{E}[z_t] = 0$, $\mathrm{Var}(z_t) = 1$. Hai hàm mật độ phân phối xác suất chuẩn hóa:

$$f_{\mathcal{N}}(z) = \frac{1}{\sqrt{2\pi}} \exp\!\left(-\tfrac{1}{2} z^2\right), \tag{2.1}$$

$$f_{t^*}(z;\nu) = \frac{\Gamma\!\left(\frac{\nu+1}{2}\right)}{\sqrt{\pi(\nu-2)}\,\Gamma\!\left(\frac{\nu}{2}\right)} \left(1 + \frac{z^2}{\nu-2}\right)^{-\frac{\nu+1}{2}}, \qquad \nu > 2. \tag{2.2}$$

Mật độ (2.2) là phân phối Student-t đã chuẩn hóa về phương sai đơn vị, ký hiệu t^*_ν. Thừa số $\nu - 2$ thay cho ν dưới dấu căn chính là phép co giãn bảo đảm $\mathrm{Var}(z_t) = 1$; nhờ đó $h_{t,s}$ giữ đúng ý nghĩa phương sai có điều kiện và so sánh trực tiếp được với trường hợp sai số chuẩn. Ràng buộc $\nu > 2$ vì vậy không phải quy ước kỹ thuật mà là điều kiện tồn tại của chính phép chuẩn hóa.

2.2 Họ mô hình một trạng thái

Ba mô hình đối chứng là các trường hợp riêng của một đặc tả chung:

$$r_t = \mu + \varepsilon_t, \qquad h_t = \omega + \alpha\varepsilon_{t-1}^2 + \beta h_{t-1} + \boldsymbol{\gamma}^\top \mathbf{X}_{t-1}. \tag{2.3}$$

Trong (2.3), ω là mức phương sai nền, α đo phản ứng của phương sai với cú sốc mới, β đo mức độ dai dẳng của biến động, và $\boldsymbol{\gamma}$ đo ảnh hưởng của thông tin ngoại sinh.

Bảng 3: Sáu mô hình một trạng thái: hai họ phương sai × ba mức cấu trúc

Mô hình	Phương trình	Phân phối z_t	$\boldsymbol{\gamma}$	Số tham số	Thành phần cấu trúc
GARCH chuẩn	(2.3)	$\mathcal{N}(0,1)$	$\equiv \mathbf{0}$	4	Mốc so sánh
GARCH Student-t	(2.3)	t_ν^*	$\equiv \mathbf{0}$	5	Đuôi dày
GARCH-X Student-t	(2.3)	t_ν^*	$\in \mathbb{R}^k$	$5 + k$	Đuôi dày, ngoại sinh
EGARCH chuẩn	(2.5)	$\mathcal{N}(0,1)$	$\equiv \mathbf{0}$	5	Bất đối xứng
EGARCH Student-t	(2.5)	t_ν^*	$\equiv \mathbf{0}$	6	Bất đối xứng, đuôi dày
EGARCH-X Student-t	(2.5)	t_ν^*	$\in \mathbb{R}^k$	$6 + k$	Cả ba thành phần

Ghi chú: Với $k = 2$ biến ngoại sinh, GARCH-X Student-t có 7 tham số và EGARCH-X Student-t có 8. Chênh lệch cố định $+1$ giữa hai họ là hệ số đòn bẩy θ trong (2.5).

Giả định 2.1 (Điều kiện chính quy của mô hình một trạng thái)**.** $\omega > 0$, $\alpha \geq 0$, $\beta \geq 0$. Dừng hiệp phương sai yếu khi $\alpha + \beta < 1$, khi đó phương sai vô điều kiện là

$$\bar{h} = \frac{\omega}{1 - \alpha - \beta}. \tag{2.4}$$

Với sai số t_ν^*, moment bậc bốn tồn tại khi $\nu > 4$ và $3\alpha^2 \frac{\nu-2}{\nu-4} + 2\alpha\beta + \beta^2 < 1$.

Nhận xét 2.1 (Tính dương của phương sai khi có biến ngoại sinh)**.** Trong (2.3), tổ hợp $\boldsymbol{\gamma}^\top \mathbf{X}_{t-1}$ có thể nhận giá trị âm, nên ràng buộc dấu của (ω, α, β) *không còn đủ* để bảo đảm $h_t > 0$. Đây là khác biệt bản chất giữa GARCH-X và GARCH cổ điển. Tính dương phải được xử lý bằng một cơ chế tường minh, hoặc bằng ràng buộc miền giá trị, hoặc bằng hàm liên kết bảo toàn dấu. Trong nghiên cứu này, tính dương được kiểm tra hậu nghiệm: Tại nghiệm ước lượng của mọi mô hình, vế phải của (2.3) dương tại mọi thời điểm trong mẫu, nên đặc tả cộng tính giữ nguyên hiệu lực.

2.3 Họ mô hình EGARCH

Đặc tả (2.3) cộng tính *trên thang phương sai* và đối xứng: cú sốc ε_{t-1} chỉ đi vào qua bình phương ε_{t-1}^2, nên một cú sốc âm và một cú sốc dương cùng độ lớn tác động hệt như nhau lên h_t. Họ EGARCH [26] thay cả hai đặc điểm đó bằng cách mô hình hóa *logarit* của phương sai:

$$\ln h_t = \omega + \alpha\left(|z_{t-1}| - \mathbb{E}|z_{t-1}|\right) + \theta\, z_{t-1} + \beta \ln h_{t-1} + \boldsymbol{\gamma}^\top \mathbf{X}_{t-1}, \qquad z_{t-1} = \frac{\varepsilon_{t-1}}{\sqrt{h_{t-1}}}. \tag{2.5}$$

Bốn số hạng mang bốn vai trò tách bạch. Số hạng $\alpha(|z_{t-1}| - \mathbb{E}|z_{t-1}|)$ là *hiệu ứng độ lớn*: nó phản ứng với biên độ cú sốc chuẩn hóa, đã trừ đi kỳ vọng nên có trung bình không. Số hạng θz_{t-1} là *hiệu ứng dấu*, tức hiệu ứng đòn bẩy: khi $\theta < 0$, một cú sốc âm làm tăng $\ln h_t$ nhiều hơn một cú sốc dương cùng độ lớn. Hệ số β đo độ dai dẳng của log-phương sai, và $\boldsymbol{\gamma}^\top \mathbf{X}_{t-1}$ vẫn là kênh thông tin ngoại sinh như ở (2.3).

Hằng số $\mathbb{E}|z_t|$ phụ thuộc phân phối sai số và có dạng đóng ở cả hai trường hợp dùng trong nghiên cứu:

$$\mathbb{E}|z_t| = \sqrt{\frac{2}{\pi}} \qquad \text{khi } z_t \sim \mathcal{N}(0,1), \tag{2.6}$$

$$\mathbb{E}|z_t| = \frac{2\sqrt{\nu-2}\,\Gamma\left(\frac{\nu+1}{2}\right)}{(\nu-1)\sqrt{\pi}\,\Gamma\left(\frac{\nu}{2}\right)} \qquad \text{khi } z_t \sim t_\nu^*,\ \nu > 2. \tag{2.7}$$

Hai biểu thức này nhất quán với nhau: khi $\nu \to \infty$, tỷ số $\Gamma(\frac{\nu+1}{2})/\Gamma(\frac{\nu}{2})$ tiệm cận $\sqrt{\nu/2}$, nên vế phải của (2.7) hội tụ về $\sqrt{2/\pi}$ — đúng bằng (2.6). Đây là một phép kiểm tra bắt buộc khi cài đặt, vì sai sót ở hằng số này làm lệch toàn bộ mức nền của phương trình phương sai mà không sinh ra bất kỳ cảnh báo số học nào.

Giả định 2.2 (Điều kiện chính quy của EGARCH)**.** Điều kiện dừng của lý thuyết là $|\beta| < 1$; các hệ số ω, α, θ và $\boldsymbol{\gamma}$ *không chịu ràng buộc dấu*. Với sai số t_ν^*, vẫn giữ $\nu > 2$ để phép chuẩn hóa phương sai đơn vị tồn tại. Khi $|\beta| < 1$, quá trình $\ln h_t$ là một AR(1) dừng với trung bình vô điều kiện

$$\mathbb{E}[\ln h_t] = \frac{\omega + \boldsymbol{\gamma}^\top \mathbb{E}[\mathbf{X}_{t-1}]}{1-\beta}. \tag{2.8}$$

Nhận xét 2.2 (Miền giá trị của β dùng trong cài đặt)**.** Lý thuyết chỉ đòi hỏi $|\beta| < 1$, nhưng cả ba phương pháp suy diễn trong nghiên cứu đều tìm nghiệm trên miền hẹp hơn $\beta \in (0,1)$. Lý do là một ràng buộc phương pháp luận chứ không phải kỹ thuật: nguyên tắc xuyên suốt của nghiên cứu là ba phương pháp phải làm việc trên *cùng một hàm likelihood và cùng một không gian tham số*, để mọi chênh lệch kết quả quy được về bản chất phương pháp. Tiên nghiệm Bayes của β là phân phối Beta trên $(0,1)$; nếu để hợp lý cực đại tìm trên $(-1,1)$ thì hai khung suy diễn sẽ tìm trên hai miền khác nhau và phép so sánh mất hiệu lực. Ngoài ra, độ dai dẳng *âm* của log-phương sai — tức biến động cao hôm nay kéo theo biến động thấp ngày mai một cách hệ thống — không có ý nghĩa kinh tế trong bối cảnh này. Ràng buộc này được công bố ở đây vì nó thu hẹp không gian nghiệm so với điều kiện lý thuyết.

Nhận xét 2.3 (EGARCH giải quyết tính dương theo cấu trúc)**.** Vế trái của (2.5) là $\ln h_t$, nên $h_t = \exp(\cdot) > 0$ với *mọi* giá trị của vế phải, kể cả khi $\boldsymbol{\gamma}^\top \mathbf{X}_{t-1}$ âm tùy ý. Điều này loại bỏ hoàn toàn vấn đề nêu ở remark 2.1: không cần ràng buộc dấu trên (ω, α, β), không cần kiểm tra hậu nghiệm, không cần sàn cắt. Đây là lý do phương pháp luận chính để đưa họ EGARCH vào nghiên cứu, bên cạnh khả năng nắm bắt bất đối xứng. Đổi lại, cài đặt cần một lớp bảo vệ số học khác: chặn $\ln h_t$ trong một khoảng hữu hạn để $\exp(\cdot)$ không tràn số.

Nhận xét 2.4 (Moment vô điều kiện của EGARCH với sai số Student-t)**.** Điều kiện $|\beta| < 1$ bảo đảm $\ln h_t$ dừng, nhưng *không* bảo đảm h_t có moment vô điều kiện hữu hạn. Kỳ vọng $\mathbb{E}[h_t]$ chứa thừa số dạng $\mathbb{E}[\exp(\alpha|z| + \theta z)]$, tức hàm sinh moment của z. Với $z \sim \mathcal{N}(0,1)$ đại lượng này hữu hạn; với $z \sim t_\nu^*$ thì hàm sinh moment *không tồn tại*, nên $\mathbb{E}[h_t] = \infty$ theo nghĩa chặt. Nelson [26] vì lý do này dùng phân phối sai số lũy thừa tổng quát thay cho Student-t. Nghiên cứu vẫn dùng EGARCH Student-t và công bố rõ giới hạn: mô hình *có điều kiện* vẫn xác định đầy đủ — hàm likelihood tính được, dự báo một bước và mọi tiêu chí đánh giá ở Mục 5 đều là đại lượng có điều kiện — nên kết quả thực nghiệm không bị ảnh hưởng; điều không phát biểu được là các tính chất *vô điều kiện* của quá trình. Việc đưa EGARCH chuẩn vào danh mục cũng phục vụ mục đích này: đó là biến thể EGARCH duy nhất trong bài không vướng vấn đề trên.

Nhận xét 2.5 (Chi phí tính toán của (2.5))**.** Ở (2.3), đại lượng ε_{t-1}^2 không phụ thuộc h nên tính sẵn được cho mọi t trước khi vào vòng lặp. Ở (2.5) thì $z_{t-1} = \varepsilon_{t-1}/\sqrt{h_{t-1}}$ *phụ thuộc chính* h_{t-1}, nên phải tính bên trong vòng lặp. Khác biệt này không đổi công thức nhưng làm mỗi bước lặp đắt thêm một phép căn và một phép chia.

2.4 Trạng thái ẩn và xích Markov

Chế độ thị trường là biến ẩn $S_t \in \{1, 2\}$ tuân theo xích Markov thuần nhất bậc một:

$$\mathbf{P} = \begin{pmatrix} p_{11} & 1 - p_{11} \\ 1 - p_{22} & p_{22} \end{pmatrix}, \qquad p_{ij} = \mathbb{P}(S_t = j \mid S_{t-1} = i)\,. \tag{2.9}$$

Khi $0 < p_{11} < 1$ và $0 < p_{22} < 1$, xích bất khả quy và không tuần hoàn, nên tồn tại duy nhất phân phối dừng $\boldsymbol{\pi}$ thỏa $\boldsymbol{\pi}^\top \mathbf{P} = \boldsymbol{\pi}^\top$:

$$\pi_1 = \frac{1 - p_{22}}{2 - p_{11} - p_{22}}, \qquad \pi_2 = \frac{1 - p_{11}}{2 - p_{11} - p_{22}}. \tag{2.10}$$

Số phiên liên tiếp ở lại một trạng thái tuân theo phân phối hình học với xác suất thành công $1 - p_{ss}$, nên thời gian tồn tại kỳ vọng là

$$d_s = \frac{1}{1 - p_{ss}}. \tag{2.11}$$

Đại lượng (2.11) là cầu nối giữa tham số thống kê p_{ss} và một phát biểu kinh tế kiểm chứng được về độ bền của chế độ biến động.

2.5 Phụ thuộc đường đi và thu gọn moment

Trong lớp mô hình GARCH tiêu chuẩn, phương sai có điều kiện h_t phụ thuộc đệ quy vào phương sai quá khứ h_{t-1}. Khi tích hợp cơ chế Markov ẩn, các hệ số của phương trình phương

sai trở thành hàm phụ thuộc vào trạng thái S_t. Sự kết hợp này dẫn đến một hệ quả cấu trúc được thể hiện ở phương trình (2.12): h_t không chỉ phụ thuộc vào trạng thái hiện tại S_t mà còn phụ thuộc vào h_{t-1}. Do h_{t-1} tiếp tục phụ thuộc vào S_{t-1} và h_{t-2}, tính đệ quy này khiến h_t phụ thuộc vào toàn bộ đường đi của lịch sử trạng thái $\mathbf{S}_t = (S_1, \dots, S_t)$:

$$h_t(\mathbf{S}_t) = \omega_{S_t} + \alpha_{S_t}\varepsilon_{t-1}^2 + \beta_{S_t}h_{t-1}(\mathbf{S}_{t-1}). \tag{2.12}$$

Với mô hình gồm 2 trạng thái, số lượng kịch bản đường đi tại thời điểm t sẽ có tổ hợp lên đến 2^t. Việc tối ưu hóa hàm likelihood chính xác đòi hỏi phải tính toán trên toàn bộ các nhánh này, dẫn đến một bài toán không thể giải quyết trong thời gian đa thức. Để phá vỡ sự phụ thuộc này, Gray [15] đề xuất phương pháp thu gọn moment, thay thế các đại lượng trễ bằng moment hỗn hợp dựa trên xác suất lọc $\xi_{t-1|t-1}(i)$:

$$\bar{\mu}_{t-1} = \sum_{i=1}^{2} \xi_{t-1|t-1}(i)\,\mu_i, \tag{2.13}$$

$$\bar{h}_{t-1} = \sum_{i=1}^{2} \xi_{t-1|t-1}(i)\left[h_{t-1,i} + \mu_i^2\right] - \bar{\mu}_{t-1}^2, \tag{2.14}$$

$$\bar{\varepsilon}_{t-1} = r_{t-1} - \bar{\mu}_{t-1}. \tag{2.15}$$

Mệnh đề 2.1 (Dạng tương đương của (2.14))**.** Phương trình (2.14) tương đương với dạng phương sai của hỗn hợp:

$$\bar{h}_{t-1} = \sum_{i=1}^{2} \xi_{t-1|t-1}(i)\left[h_{t-1,i} + (\mu_i - \bar{\mu}_{t-1})^2\right]. \tag{2.16}$$

Chứng minh. Đặt $\xi_i = \xi_{t-1|t-1}(i)$. Khai triển bình phương và sử dụng tính chất $\sum_i \xi_i = 1$ cùng định nghĩa (2.13):

$$\sum_i \xi_i(\mu_i - \bar{\mu}_{t-1})^2 = \sum_i \xi_i\mu_i^2 - 2\bar{\mu}_{t-1}\sum_i \xi_i\mu_i + \bar{\mu}_{t-1}^2 = \sum_i \xi_i\mu_i^2 - \bar{\mu}_{t-1}^2$$

Cộng đại lượng $\sum_i \xi_i h_{t-1,i}$ vào hai vế, ta thu được (2.14). □

Dạng biểu diễn (2.16) làm rõ ý nghĩa thống kê trực quan: Phương sai hỗn hợp chính là tổng của trung bình có trọng số các phương sai biến thiên trong nội bộ trạng thái và độ phân tán của các trung bình quanh kỳ vọng biến thiên giữa các trạng thái.

Nhận xét 2.6. Sau khi thay thế $\bar{\mu}_{t-1}$ và $\bar{h}_{t-1}$ vào phương trình phương sai, quá trình trên lấy lại được tính chất Markov. Nhờ đó, bộ lọc tiến ở Mục 3.1 là *chính xác* đối với mô hình đã thu gọn. Cần nhấn mạnh rằng (3.6) là hàm log-likelihood đúng của mô hình thu gọn, chứ không phải xấp xỉ của hàm gốc; toàn bộ bản chất xấp xỉ chỉ giới hạn ở bước thu gọn (2.13)–(2.14). Đặc

điểm này thiết lập một điều kiện nền tảng mang tính phương pháp luận cho phần thứ hai: Do ba phương pháp suy diễn đều vận hành trên cùng một cấu trúc hàm likelihood, mọi chênh lệch trong kết quả ước lượng đều xuất phát từ bản chất của phương pháp tối ưu, hoàn toàn không bị nhiễu bởi cơ chế thu gọn moment.

2.6 Mô hình chuyển trạng thái và mô hình chính

Mô hình chính của nghiên cứu, MS-GARCH-X Student-t, được xác định bởi hệ

$$r_t = \mu_{S_t} + \varepsilon_t, \tag{2.17}$$

$$\varepsilon_t = \sqrt{h_{t,S_t}}\, z_t, \tag{2.18}$$

$$z_t \sim t_\nu^*, \qquad \nu > 2, \tag{2.19}$$

$$h_{t,s} = \omega_s + \alpha_s \bar{\varepsilon}_{t-1}^2 + \beta_s \bar{h}_{t-1} + \boldsymbol{\gamma}_s^\top \mathbf{X}_{t-1}, \qquad s \in \{1,2\}. \tag{2.20}$$

Mô hình đối chứng MS-GARCH chuẩn thu được bằng cách đặt $z_t \sim \mathcal{N}(0,1)$ và $\boldsymbol{\gamma}_s \equiv \mathbf{0}$; mô hình này tách riêng đóng góp của cơ chế chuyển trạng thái khỏi đóng góp của đuôi dày và biến ngoại sinh. Vector tham số của mô hình chính:

$$\boldsymbol{\theta} = \left(\mu_1, \mu_2,\ \omega_1, \omega_2,\ \alpha_1, \alpha_2,\ \beta_1, \beta_2,\ \boldsymbol{\gamma}_1^\top, \boldsymbol{\gamma}_2^\top,\ p_{11}, p_{22},\ \nu\right)^\top \in \Theta \subset \mathbb{R}^{11+2k}. \tag{2.21}$$

Với $k = 2$ biến ngoại sinh, $\dim(\boldsymbol{\theta}) = 15$.

Giả định 2.3 (Điều kiện chính quy của mô hình chuyển trạng thái)**.**

(C1) **Tính Ergodic:** $0 < p_{11} < 1$ và $0 < p_{22} < 1$, bảo đảm tồn tại duy nhất phân phối dừng (2.10).

(C2) **Tính dương của phương sai:** $\omega_s > 0$, $\alpha_s \geq 0$, $\beta_s \geq 0$, và $h_{t,s} > 0$ với mọi t, s.

(C3) **Tồn tại phương sai có điều kiện:** $\nu > 2$.

Nhận xét 2.7. Với lớp MS-GARCH của Haas, Mittnik và Paolella [16], trong đó mỗi trạng thái giữ một phương sai riêng không thu gọn, điều kiện dừng bậc hai có dạng đóng qua bán kính phổ của một ma trận sinh từ **P** và các hệ số (α_s, β_s). Biến thể thu gọn kiểu Gray dùng ở đây không thuộc lớp đó, nên điều kiện ấy không áp dụng trực tiếp và tài liệu này không phát biểu nó như một tính chất tiên nghiệm của mô hình. Điểm cần ghi nhận là ràng buộc $\alpha_s + \beta_s < 1$ cho *từng* trạng thái không phải điều kiện cần: Một trạng thái có thể bùng nổ cục bộ mà hệ thống chung vẫn dừng, miễn là xác suất ở lại trạng thái đó đủ nhỏ [13]. Vì vậy nghiên cứu áp đặt (C1)–(C3) như điều kiện vận hành và đánh giá tính hợp lý của nghiệm qua thời gian tồn tại kỳ vọng d_s theo (2.11).

2.7 Nhận dạng nhãn trạng thái

Hàm likelihood bất biến dưới phép hoán vị nhãn: Đổi đồng thời $(\mu_1, \omega_1, \alpha_1, \beta_1, \boldsymbol{\gamma}_1)$ với $(\mu_2, \omega_2, \alpha_2, \beta_2, \boldsymbol{\gamma}_2)$ và p_{11} với p_{22} cho cùng một giá trị likelihood. Sự không nhận dạng được này dẫn tới hai hệ quả khác nhau ở hai phương pháp suy diễn: Trong phương pháp Maximum Likelihood Estimation (MLE), nó tạo ra hai cực đại địa phương đối xứng; trong suy diễn biến phân và MCMC, nó có thể làm phân phối hậu nghiệm bị đa mode nhân tạo (label switching).

Định nghĩa 2.1 (Quy ước nhận dạng nhãn)**.** Trạng thái 1 được quy ước là trạng thái có mức phương sai dài hạn nhỏ hơn:

$$\frac{\omega_1}{1-\alpha_1-\beta_1} < \frac{\omega_2}{1-\alpha_2-\beta_2}. \tag{2.22}$$

Khi một trong hai trạng thái bùng nổ cục bộ ($\alpha_s + \beta_s \geq 1$, mẫu số không dương), quy ước thay thế bằng:

$$\omega_1 < \omega_2. \tag{2.23}$$

Quy ước áp dụng *sau* khi ước lượng: Cho nghiệm điểm trong khung hợp lý cực đại, và cho từng mẫu rút từ phân phối biến phân $q(\boldsymbol{\phi})$ trước khi tính các moment hậu nghiệm. Trong suy diễn Bayes, việc kiểm tra và hoán vị nhãn theo từng mẫu là bắt buộc: Nếu chỉ sắp lại nhãn cho ước lượng tổng hợp, các moment hậu nghiệm đã bị trộn lẫn giữa hai trạng thái và mất ý nghĩa kinh tế.

Nhận xét 2.8 (Đổi nhãn trong suy diễn Bayes)**.** Khi phân phối biến phân $q(\boldsymbol{\phi})$ có phương sai đủ lớn hoặc bao trùm cả hai cực đại đối xứng, các mẫu sinh ra từ q không nhất thiết giữ cùng một quy ước nhãn. Tỷ lệ mẫu vi phạm (2.22) đo lường mức độ mà phương pháp suy diễn tách biệt hay không phân biệt được hai trạng thái: Danh tính trạng thái đổi qua lại ngay giữa các mẫu của cùng một lần chạy. Khi đó, việc sắp lại nhãn (relabeling) là cần thiết để khôi phục tính nhất quán của các khoảng tin cuộc hậu nghiệm.

Nhận xét 2.9 (Tỷ lệ hoán vị nhãn như một chẩn đoán)**.** Tỷ lệ mẫu hậu nghiệm phải hoán vị nhãn mang thông tin độc lập với các chẩn đoán hội tụ thông thường. Tỷ lệ gần 0 hoặc gần 1 tương ứng với một quy ước nhất quán toàn cục và vô hại. Tỷ lệ gần $1/2$ cho thấy phân phối hậu nghiệm không phân biệt được hai trạng thái: danh tính trạng thái đổi qua lại ngay giữa các mẫu của cùng một lần chạy. Khi đó mọi đại lượng theo trạng thái mất ý nghĩa, kể cả khi các chẩn đoán khác đạt chuẩn.

3 Ước lượng hợp lý cực đại

3.1 Bộ lọc tiến Hamilton

Với mô hình một trạng thái, log-likelihood tính trực tiếp từ mật độ có điều kiện. Với mô hình chuyển trạng thái, biến ẩn S_t phải được biên hóa. Bộ lọc tiến [17] thực hiện việc này bằng bốn bước lặp, khởi tạo $\xi_{1|0}(s) = \pi_s$ theo (2.10).

Bước 1: Dự báo trạng thái. Từ xác suất lọc của phiên trước, xác suất trạng thái trước khi quan sát r_t là

$$\xi_{t|t-1}(j) = \mathbb{P}(S_t = j \mid \mathcal{F}_{t-1}) = \sum_{i=1}^{2} p_{ij}\, \xi_{t-1|t-1}(i). \tag{3.1}$$

Bước 2: Mật độ có điều kiện theo từng trạng thái. Giả sử $S_t = j$, lợi suất có mật độ

$$\eta_{t,j} = f(r_t \mid S_t = j, \mathcal{F}_{t-1}; \boldsymbol{\theta}) = \frac{1}{\sqrt{h_{t,j}}} \cdot f\!\left(\frac{r_t - \mu_j}{\sqrt{h_{t,j}}}\right), \tag{3.2}$$

trong đó f là $f_{\mathcal{N}}$ theo (2.1) hoặc f_{t^*} theo (2.2) tùy mô hình.

Bước 3: Mật độ biên của quan sát. Lấy trung bình theo xác suất dự báo:

$$f(r_t \mid \mathcal{F}_{t-1}; \boldsymbol{\theta}) = \sum_{j=1}^{2} \xi_{t|t-1}(j)\, \eta_{t,j}. \tag{3.3}$$

Đây là mật độ của một *hỗn hợp hai thành phần* với trọng số thay đổi theo thời gian.

Bước 4: Cập nhật xác suất trạng thái. Sau khi quan sát r_t, công thức Bayes cho

$$\xi_{t|t}(j) = \mathbb{P}(S_t = j \mid \mathcal{F}_t) = \frac{\xi_{t|t-1}(j)\, \eta_{t,j}}{f(r_t \mid \mathcal{F}_{t-1}; \boldsymbol{\theta})}. \tag{3.4}$$

3.2 Hàm likelihood

Nhân các mật độ biên (3.3) qua toàn bộ mẫu huấn luyện thu được hàm likelihood:

$$\mathcal{L}(\boldsymbol{\theta}; \mathcal{D}_T) = \prod_{t=1}^{T} \left[\sum_{j=1}^{2} \xi_{t|t-1}(j; \boldsymbol{\theta}) \cdot \frac{1}{\sqrt{h_{t,j}(\boldsymbol{\theta})}} f\!\left(\frac{r_t - \mu_j}{\sqrt{h_{t,j}(\boldsymbol{\theta})}}\right) \right]. \tag{3.5}$$

Lấy logarit để chuyển tích thành tổng, thu được hàm log-likelihood, đây chính là hàm mục tiêu của Phần thứ nhất:

$$\ell_T(\boldsymbol{\theta}) = \ln \mathcal{L}(\boldsymbol{\theta}; \mathcal{D}_T) = \sum_{t=1}^{T} \ln \left[\sum_{j=1}^{2} \xi_{t|t-1}(j)\, \eta_{t,j} \right]. \tag{3.6}$$

Ba điểm cần lưu ý về (3.5). Thứ nhất, mọi tham số đều tham gia: $\mathbf{P}$ qua trọng số, các hệ số phương sai qua $h_{t,j}$, và ν qua dạng của f. Thứ hai, hàm likelihood *không* tách được thành tích các thừa số độc lập theo tham số, vì $h_{t,j}$ phụ thuộc đệ quy vào toàn bộ quá khứ qua (2.14). Thứ ba, với mô hình một trạng thái, tổng bên trong chỉ còn một số hạng và (3.5) rút gọn về hàm likelihood GARCH thông thường; đây là lý do năm mô hình so sánh được với nhau trên cùng một thang đo.

Khi cần mô tả lịch sử trạng thái, xác suất làm trơn tính bằng đệ quy lùi Kim [21]:

$$\xi_{t|T}(j) = \xi_{t|t}(j) \sum_{k=1}^{2} \frac{p_{jk}\, \xi_{t+1|T}(k)}{\xi_{t+1|t}(k)}. \tag{3.7}$$

Đại lượng (3.7) sử dụng thông tin sau thời điểm t nên chỉ dùng để mô tả lịch sử, không dùng làm tín hiệu thời gian thực.

3.3 Tham số hóa không ràng buộc

Bài toán $\max_{\boldsymbol{\theta}\in\Theta} \ell_T(\boldsymbol{\theta})$ có ràng buộc. Ta chuyển sang biến không ràng buộc $\boldsymbol{\phi} \in \mathbb{R}^d$ qua song ánh trơn $\boldsymbol{\theta} = g(\boldsymbol{\phi})$, tác động theo từng tọa độ:

$$\mu_s = \phi_{\mu,s}, \quad \boldsymbol{\gamma}_s = \boldsymbol{\phi}_{\gamma,s}, \quad \omega_s = e^{\phi_{\omega,s}}, \quad \alpha_s = \mathrm{softplus}(\phi_{\alpha,s}), \quad \beta_s = \mathrm{softplus}(\phi_{\beta,s}), \tag{3.8}$$

$$p_{ss} = \mathrm{sigmoid}(\phi_{p,s}), \qquad \nu = 2 + \mathrm{softplus}(\phi_\nu), \tag{3.9}$$

với $\mathrm{softplus}(x) = \ln(1 + e^x)$ có ảnh $(0, \infty)$ và $\mathrm{sigmoid}(x) = (1 + e^{-x})^{-1}$ có ảnh $(0, 1)$. Phép biến đổi này bảo đảm (C1)–(C3) *theo cấu trúc*[1] chứ không bằng kiểm tra hậu nghiệm: $\alpha_s, \beta_s > 0$, $p_{ss} \in (0, 1)$ và $\nu > 2$ với mọi $\boldsymbol{\phi} \in \mathbb{R}^d$. Lựa chọn $\omega_s = e^{\phi}$ tương thích với tiên nghiệm log-chuẩn ở Mục 4.1, bảo đảm hai khung suy diễn của Phần thứ hai làm việc trên cùng một tham số hóa.

3.4 Tính đa cực trị và nguyên tắc chọn nghiệm

Hàm likelihood của mô hình chuyển trạng thái đa cực trị. Đây không phải khiếm khuyết của thuật toán mà là tính chất của chính hàm mục tiêu, bắt nguồn từ hai nguồn: Đối xứng hoán vị nhãn ở Mục 2.7, và sự tồn tại của các cực đại giả.

Nhận xét 3.1 (Cực đại giả và điều kiện chính quy vận hành)**.** Hàm likelihood MS-GARCH có các cực đại với giá trị tùy ý lớn, ứng với một trạng thái tồn tại đúng một phiên và hấp thụ trọn một quan sát cực đoan: Phương sai của trạng thái đó co về gần không và mật độ tại điểm quan

[1] Hàm sigmoid ánh xạ $\mathbb{R} \to (0, 1)$, bảo đảm p_{ss} luôn là một xác suất hợp lệ. Hàm softplus ánh xạ một số thực ϕ_ν bất kỳ thành một số luôn dương. Khi thiết lập $\nu = 2 + \mathrm{softplus}(\phi_\nu)$, ta đang lấy 2 cộng thêm một số dương, từ đó đảm bảo tuyệt đối $\nu > 2$ một cách chặt chẽ.

sát phân kỳ. Những điểm này tối ưu về mặt số học nhưng vô nghĩa về mặt kinh tế, và một quy trình chọn nghiệm thuần túy theo giá trị likelihood sẽ chọn đúng chúng. Nghiên cứu vì vậy chọn nghiệm có likelihood cao nhất *trong số các nghiệm thỏa điều kiện chính quy vận hành*

$$d_s \geq 2 \text{ phiên} \quad \text{và} \quad p_{ss} \in [0{,}01;\ 0{,}999], \qquad s = 1, 2, \tag{3.10}$$

tức loại bỏ các nghiệm mô tả một chế độ không tồn tại đủ lâu để mang ý nghĩa chế độ, hoặc một chế độ gần như hấp thụ. Quy tắc này phải được công bố cùng kết quả, vì nó có thể loại bỏ những nghiệm có log-likelihood cao hơn nghiệm được báo cáo.

Vì hàm likelihood đa cực trị, ước lượng được thực hiện từ nhiều điểm khởi tạo độc lập, trong đó một phần sinh từ nghiệm của mô hình lồng nhau đơn giản hơn theo thứ bậc GARCH chuẩn → MS-GARCH chuẩn và GARCH-X Student-t → MS-GARCH-X Student-t. Độ tán của giá trị likelihood giữa các điểm khởi tạo là một chẩn đoán độc lập: Độ tán nhỏ củng cố tin cậy vào nghiệm, độ tán lớn cho thấy bề mặt likelihood nhiều đỉnh và kết luận cần thận trọng tương ứng.

3.5 Tiêu chí so sánh mô hình

Với $d = \dim(\boldsymbol{\theta})$ và T là cỡ mẫu huấn luyện:

$$\text{AIC} = 2d - 2\ell_T, \qquad \text{BIC} = d \ln T - 2\ell_T. \tag{3.11}$$

Cả hai phạt độ phức tạp, nhưng BIC phạt nặng hơn khi $T > e^2 \approx 7{,}4$. Với $T = 1735$, hệ số phạt của BIC là $\ln T \approx 7{,}46$ trên mỗi tham số, so với 2 của AIC; khoảng cách này đủ lớn để hai tiêu chí xếp hạng khác nhau, và khi đó BIC nghiêng về mô hình tiết kiệm tham số hơn. Trong thiết kế lồng nhau của phần thứ nhất, chênh lệch AIC và BIC giữa hai mô hình liền kề là thước đo trực tiếp giá trị gia tăng của thành phần cấu trúc vừa thêm, sau khi đã trừ chi phí tham số.

Nhận xét 3.2 (Vì sao không dùng kiểm định tỷ số likelihood)**.** So sánh mô hình một trạng thái với mô hình hai trạng thái không thực hiện được bằng kiểm định tỷ số likelihood. Dưới giả thuyết không "chỉ có một trạng thái", các tham số p_{11}, p_{22} và bộ tham số của trạng thái thứ hai *không được nhận dạng*: Hàm likelihood không phụ thuộc vào chúng. Điều kiện chính quy của định lý Wilks bị vi phạm và thống kê tỷ số likelihood không có phân phối tiệm cận χ^2 [7, 19]. Đây là lý do thứ bậc mô hình được xếp bằng (3.11) và bằng năng lực dự báo ngoài mẫu, chứ không bằng kiểm định giả thuyết.

4 Suy diễn Bayes biến phân

4.1 Phân phối tiên nghiệm

Giả định độc lập tiên nghiệm giữa các khối tham số:

$$p(\boldsymbol{\theta}) = p(\boldsymbol{\mu})\,p(\boldsymbol{\omega})\,p(\boldsymbol{\alpha})\,p(\boldsymbol{\beta})\,p(\boldsymbol{\gamma})\,p(p_{11})\,p(p_{22})\,p(\nu)$$

Với dạng giải tích của từng thành phần như sau.

Trung bình. Tiên nghiệm chuẩn, không thông tin về dấu:

$$p(\mu_s) = \frac{1}{\sqrt{2\pi}\,\sigma_\mu}\exp\!\left(-\frac{\mu_s^2}{2\sigma_\mu^2}\right), \qquad \mu_s \sim \mathcal{N}\!\left(0, \sigma_\mu^2\right). \tag{4.1}$$

Mức phương sai nền. Tiên nghiệm log-chuẩn, bảo đảm $\omega_s > 0$ và tương thích với tham số hóa (3.8):

$$p(\omega_s) = \frac{1}{\omega_s\sqrt{2\pi}\,\sigma_\omega}\exp\!\left(-\frac{(\ln\omega_s - m_\omega)^2}{2\sigma_\omega^2}\right), \qquad \ln\omega_s \sim \mathcal{N}\!\left(m_\omega, \sigma_\omega^2\right). \tag{4.2}$$

Thừa số $1/\omega_s$ là Jacobian của phép đổi biến từ $\ln\omega_s$ sang ω_s.

Hệ số ARCH và GARCH. Tiên nghiệm Beta đối xứng trên khoảng $(0, 1)$:

$$p(\alpha_s) = \frac{\alpha_s^{a-1}\,(1-\alpha_s)^{a-1}}{\mathrm{B}(a,a)}, \qquad p(\beta_s) = \frac{\beta_s^{a-1}\,(1-\beta_s)^{a-1}}{\mathrm{B}(a,a)}, \tag{4.3}$$

với $\mathrm{B}(\cdot,\cdot)$ là hàm Beta. Giá trị $a > 1$ cho mật độ đơn đỉnh, đối xứng quanh $1/2$ và triệt tiêu tại hai đầu mút (nhằm loại trừ tiên nghiệm các giá trị suy biến 0 và 1.

Hệ số biến ngoại sinh. Tiên nghiệm chuẩn nhiều chiều:

$$p(\boldsymbol{\gamma}_s) = \left(2\pi\sigma_\gamma^2\right)^{-k/2}\exp\!\left(-\frac{\|\boldsymbol{\gamma}_s\|_2^2}{2\sigma_\gamma^2}\right), \qquad \boldsymbol{\gamma}_s \sim \mathcal{N}\!\left(\mathbf{0}, \sigma_\gamma^2\mathbf{I}_k\right). \tag{4.4}$$

Xác suất ở lại trạng thái. Tiên nghiệm Beta bất đối xứng:

$$p(p_{ss}) = \frac{p_{ss}^{a_p-1}\,(1-p_{ss})^{b_p-1}}{\mathrm{B}(a_p,b_p)}, \qquad \mathbb{E}[p_{ss}] = \frac{a_p}{a_p+b_p}. \tag{4.5}$$

Chọn $a_p > b_p$ đặt phần lớn khối lượng ở vùng p_{ss} lớn, phản ánh nhận định tiên nghiệm rằng các chế độ biến động có tính dai dẳng, tương ứng thời gian tồn tại kỳ vọng (2.11) lớn hơn vài phiên.

Bậc tự do. Tiên nghiệm Gamma đặt trên $\nu - 2$ thay vì trên ν:

$$p(\nu) = \frac{b_\nu^{a_\nu}}{\Gamma(a_\nu)} (\nu - 2)^{a_\nu - 1} e^{-b_\nu(\nu-2)}, \qquad \nu - 2 \sim \text{Gamma}(a_\nu, b_\nu)\,, \tag{4.6}$$

với $\mathbb{E}[\nu] = 2 + a_\nu / b_\nu$. Cách đặt này bảo đảm $\nu > 2$ theo cấu trúc, nhất quán với điều kiện (C3), và cho phép hậu nghiệm dồn khối lượng về vùng đuôi dày nếu dữ liệu ủng hộ.

4.2 Phân phối hậu nghiệm

Theo định lý Bayes, mật độ hậu nghiệm trên không gian tham số gốc là

$$p(\boldsymbol{\theta} \mid \mathcal{D}_T) = \frac{p(\boldsymbol{\theta})\mathcal{L}(\boldsymbol{\theta}; \mathcal{D}_T)}{\displaystyle\int_\Theta p(\boldsymbol{\theta}')\,\mathcal{L}(\boldsymbol{\theta}'; \mathcal{D}_T)\,\mathrm{d}\boldsymbol{\theta}'} \propto p(\boldsymbol{\theta})\,\mathcal{L}(\boldsymbol{\theta}; \mathcal{D}_T). \tag{4.7}$$

Mẫu số của (4.7) là một tích phân 15 chiều trên miền có ràng buộc, không tính được giải tích. Đây là lý do phải dùng phương pháp xấp xỉ.

Suy diễn được thực hiện trên biến không ràng buộc $\boldsymbol{\phi}$ với cùng phép biến đổi (3.8)–(3.9). Theo công thức đổi biến cho mật độ xác suất,

$$p(\boldsymbol{\phi} \mid \mathcal{D}_T) \propto p(g(\boldsymbol{\phi})) \cdot \mathcal{L}(g(\boldsymbol{\phi}); \mathcal{D}_T) \cdot \left|\det \mathbf{J}_g(\boldsymbol{\phi})\right|. \tag{4.8}$$

Vì g tác động theo từng tọa độ, $\mathbf{J}_g$ là ma trận đường chéo và định thức là tích các đạo hàm riêng:

$$\ln \left|\det \mathbf{J}_g(\boldsymbol{\phi})\right| = \sum_{i=1}^{d} \ln \left| \frac{\partial g_i(\phi_i)}{\partial \phi_i} \right|, \tag{4.9}$$

với các thành phần

$$\frac{\partial \omega_s}{\partial \phi_{\omega,s}} = \omega_s, \qquad \frac{\partial \alpha_s}{\partial \phi_{\alpha,s}} = \text{sigmoid}(\phi_{\alpha,s}), \qquad \frac{\partial p_{ss}}{\partial \phi_{p,s}} = p_{ss}\,(1 - p_{ss})\,, \qquad \frac{\partial \nu}{\partial \phi_\nu} = \text{sigmoid}(\phi_\nu), \tag{4.10}$$

và bằng 1 đối với $\mu_s, \boldsymbol{\gamma}_s$, đóng góp 0 vào (4.9). Số hạng (4.9) không phải chi tiết kỹ thuật có thể bỏ qua: Thiếu nó, mật độ trên $\boldsymbol{\phi}$ không còn là ảnh đúng của hậu nghiệm trên Θ, và mọi moment tính từ đó đều lệch một cách hệ thống.

4.3 Cận dưới của hàm Likelihood biên (ELBO – Evidence Lower Bound)

Suy diễn biến phân chọn một họ phân phối $\mathcal{Q}$ và tìm phần tử gần hậu nghiệm nhất theo phân kỳ Kullback–Leibler (KL Divergence) [3]:

$$q^\star = \arg\min_{q\in\mathcal{Q}} \mathrm{KL}(q(\boldsymbol{\phi}) \,\|\, p(\boldsymbol{\phi} \mid \mathcal{D}_T)), \qquad \mathrm{KL}(q\|p) = \int q(\boldsymbol{\phi}) \ln \frac{q(\boldsymbol{\phi})}{p(\boldsymbol{\phi} \mid \mathcal{D}_T)} \, \mathrm{d}\boldsymbol{\phi}. \tag{4.11}$$

Bài toán (4.11) không giải trực tiếp được vì $p(\boldsymbol{\phi} \mid \mathcal{D}_T)$ chứa hằng số chuẩn hóa chưa biết. Tuy nhiên, với mọi $q \in \mathcal{Q}$ ta có phân rã đồng nhất

$$\ln p(\mathcal{D}_T) = \mathrm{ELBO}(q) + \mathrm{KL}(q\|p) \tag{4.12}$$

Vì vế trái là hằng số theo q và $\mathrm{KL} \geq 0$, cực tiểu hóa KL tương đương cực đại hóa ELBO; đồng thời $\mathrm{ELBO}(q) \leq \ln p(\mathcal{D}_T)$ với mọi q, dấu bằng xảy ra khi và chỉ khi q trùng hậu nghiệm. Dạng tường minh của cận dưới:

$$\mathrm{ELBO}(q) = \mathbb{E}_{q(\boldsymbol{\phi})}\Big[\ell_T(g(\boldsymbol{\phi})) + \ln p(g(\boldsymbol{\phi})) + \ln \left|\det \mathbf{J}_g(\boldsymbol{\phi})\right|\Big] + \mathcal{H}(q), \tag{4.13}$$

với $\mathcal{H}(q) = -\mathbb{E}_q[\ln q(\boldsymbol{\phi})]$. Ba số hạng đầu kéo q về vùng có hậu nghiệm cao; số hạng entropy chống lại xu hướng co q về một điểm. Cân bằng giữa hai lực này quyết định độ rộng của q.

4.4 Hai họ phân phối biến phân

Định nghĩa 4.1 (Mean-field)**.** Phân phối biến phân có dạng tích các hàm mật độ xác suất phân phối chuẩn một chiều:

$$q_{\mathrm{MF}}(\boldsymbol{\phi}) = \prod_{i=1}^{d} \frac{1}{\sqrt{2\pi}\, s_i} \exp\left(-\frac{(\phi_i - m_i)^2}{2s_i^2}\right) = \mathcal{N}\big(\boldsymbol{\phi} \mid \mathbf{m},\ \mathrm{diag}(s_1^2, \ldots, s_d^2)\big), \tag{4.14}$$

với tham số biến phân $(\mathbf{m}, \mathbf{s})$ gồm $2d$ thành phần. Entropy có dạng đóng

$$\mathcal{H}(q_{\mathrm{MF}}) = \frac{d}{2}(1 + \ln 2\pi) + \sum_{i=1}^{d} \ln s_i. \tag{4.15}$$

Gradient của (4.13) ước lượng không chệch qua phép tái tham số hóa $\phi_i = m_i + s_i\varepsilon_i$ với $\varepsilon_i \sim \mathcal{N}(0,1)$ độc lập [22].

Định nghĩa 4.2 (Full-rank)**.** Phân phối biến phân là phân phối chuẩn nhiều chiều với ma trận

hiệp phương sai đầy đủ, tham số hóa qua thừa số Cholesky:

$$q_{\mathrm{FR}}(\boldsymbol{\phi}) = \frac{1}{(2\pi)^{d/2}\,|\boldsymbol{\Sigma}|^{1/2}} \exp\!\Big(-\tfrac{1}{2}\,(\boldsymbol{\phi}-\mathbf{m})^{\top}\,\boldsymbol{\Sigma}^{-1}\,(\boldsymbol{\phi}-\mathbf{m})\Big), \qquad \boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}^{\top}, \tag{4.16}$$

với $\mathbf{L}$ tam giác dưới có đường chéo dương. Tham số biến phân $(\mathbf{m}, \mathrm{vech}(\mathbf{L}))$ gồm $d + d(d+1)/2$ thành phần. Entropy

$$\mathcal{H}(q_{\mathrm{FR}}) = \frac{d}{2}\,(1 + \ln 2\pi) + \sum_{i=1}^{d} \ln L_{ii}, \tag{4.17}$$

và tái tham số hóa $\boldsymbol{\phi} = \mathbf{m} + \mathbf{L}\boldsymbol{\varepsilon}$ với $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$.

Phân rã $\boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}^{\top}$ với $L_{ii} > 0$ bảo đảm $\boldsymbol{\Sigma}$ xác định dương theo cấu trúc và là duy nhất; đây là lý do tối ưu hóa thực hiện trên $\mathbf{L}$ chứ không trực tiếp trên $\boldsymbol{\Sigma}$. So sánh (4.15) với (4.17) cho thấy mean-field là trường hợp riêng của full-rank khi $\mathbf{L}$ bị ràng buộc là ma trận đường chéo.

Nhận xét 4.1 (Đánh đổi giữa hai họ)**.** Với $d = 15$, mean-field tối ưu 30 tham số còn full-rank tối ưu 135. Mean-field áp đặt $\mathrm{Cov}_q(\phi_i, \phi_j) = 0$, triệt tiêu tương quan hậu nghiệm (đáng kể nhất là tương quan âm giữa α_s và β_s, vốn là đặc trưng của họ GARCH) và do dạng bất đối xứng của $\mathrm{KL}(q\|p)$ trong (4.11), xu hướng hệ thống là đánh giá thấp phương sai hậu nghiệm. Full-rank không có hạn chế đó và về lý thuyết cho cận dưới khít hơn. Tuy nhiên, vì cả hai chỉ cho *cận dưới*, một họ giàu hơn không bảo đảm nghiệm tốt hơn trên thực tế: Khi bài toán tối ưu 135 tham số không được giải tốt, full-rank có thể cho ELBO thấp hơn mean-field. Đây là khả năng phải kiểm tra bằng thực nghiệm, không loại trừ được bằng lý thuyết, và là một trong những câu hỏi mà Phần thứ hai trả lời.

Nhận xét 4.2 (Phạm vi so sánh được của ELBO)**.** ELBO là cận dưới của $\ln p(\mathcal{D}_T)$ *dưới một mô hình xác suất cụ thể.* Khi đổi tiên nghiệm, đại lượng được cận dưới cũng đổi theo, nên ELBO của hai biến thể tiên nghiệm khác nhau không so sánh trực tiếp được và không dùng để chọn tiên nghiệm. Trong cùng một đặc tả, ELBO so sánh được giữa mean-field và full-rank, vì khi đó chỉ họ $\mathcal{Q}$ thay đổi; và đây chính là cơ sở để đối chiếu hai phương pháp biến phân.

4.5 Suy diễn MCMC bằng NUTS

Khác với VB, MCMC không xấp xỉ hậu nghiệm bằng một họ phân phối $\mathcal{Q}$ mà sinh trực tiếp một dãy mẫu $\boldsymbol{\phi}^{(1)}, \ldots, \boldsymbol{\phi}^{(M)}$ hội tụ về phân phối mục tiêu (4.8). Nghiên cứu dùng No-U-Turn Sampler (NUTS) [20], một biến thể tự động hóa của Hamiltonian Monte Carlo (HMC).

Cơ chế. Coi $-\ln p(\boldsymbol{\phi} \mid \mathcal{D}_T)$ như một thế năng, HMC gán cho $\boldsymbol{\phi}$ một động lượng phụ $\mathbf{r} \sim \mathcal{N}(\mathbf{0}, \mathbf{M})$ rồi mô phỏng chuyển động theo phương trình Hamilton bằng phép tích phân *leapfrog*, giữ gần bảo toàn năng lượng nên đề xuất được chấp nhận với xác suất cao. Mỗi bước leapfrog cần đúng một lần tính $\nabla_{\boldsymbol{\phi}} \ln p(\boldsymbol{\phi} \mid \mathcal{D}_T)$, tức một lượt chạy đầy đủ bộ lọc tiến Mục 3.1 cùng lan truyền ngược. NUTS tự động chọn độ dài quỹ đạo bằng cách nhân đôi số

bước $(1, 2, 4, 8, \dots)$ đến khi quỹ đạo bắt đầu quay đầu về điểm xuất phát hoặc chạm trần độ sâu cây D, nên số bước leapfrog tối đa của một mẫu là $2^D - 1$. Ma trận khối lượng $\mathbf{M}$ có thể là đường chéo hoặc đầy đủ (*dense mass matrix*), được thích nghi trong giai đoạn khởi động (*warmup*) cùng với bước tích phân.

Chẩn đoán hội tụ. Với C chuỗi độc lập, thống kê Gelman–Rubin

$$\widehat{R} = \sqrt{\frac{\widehat{\mathrm{Var}}^{+}(\boldsymbol{\phi})}{W}}, \tag{4.18}$$

so sánh phương sai ước lượng gộp $\widehat{\mathrm{Var}}^{+}$ (kết hợp trong chuỗi và giữa các chuỗi) với phương sai trung bình trong chuỗi W; $\widehat{R} \to 1$ khi các chuỗi đã trộn lẫn hoàn toàn, ngưỡng chấp nhận thông thường là $\widehat{R} < 1{,}01$. Cỡ mẫu hiệu quả (*effective sample size*, ESS) quy đổi M mẫu tự tương quan thành số mẫu độc lập tương đương; ESS nhỏ so với M cho thấy các mẫu liên tiếp gần như lặp lại thông tin của nhau.

Nhận xét 4.3 (Vì sao MCMC đắt hơn MLE nhiều bậc độ lớn)**.** Một lần đánh giá $\ell_T(\boldsymbol{\theta})$ hay $\nabla\ell_T(\boldsymbol{\theta})$ tốn chi phí như nhau ở MLE và MCMC. Khác biệt nằm ở số lần đánh giá: L-BFGS trong MLE cần vài trăm lượt trên toàn bộ quá trình tối ưu, trong khi một mẫu NUTS có thể cần tới $2^D - 1$ lượt, và nghiên cứu cần hàng nghìn mẫu trên nhiều chuỗi độc lập để có ESS đủ lớn. Tích số này giải thích chênh lệch thời gian đo được trong thực nghiệm (Mục 5): MCMC tốn tổng cộng khoảng 9 lần thời gian của MLE cho mô hình chính, dù đây đã là chi phí dồn của nhiều lần chạy thất bại, không phải một lần chạy hội tụ.

4.6 Đối chiếu bốn phương pháp suy diễn

Bảng 4: Đối chiếu bốn phương pháp suy diễn trên mô hình MS-GARCH-X Student-t

Tiêu chí	Hợp lý cực đại	Biến phân mean-field	Biến phân full-rank	MCMC (NUTS)
Đối tượng tối ưu/mô phỏng	$\ell_T(\boldsymbol{\theta})$, (3.6)	ELBO(q), (4.13)	ELBO(q), (4.13)	$p(\boldsymbol{\phi} \mid \mathcal{D}_T)$ đúng, (4.8)
Kết quả suy diễn	Một điểm $\hat{\boldsymbol{\theta}}$	Phân phối q_{MF}	Phân phối q_{FR}	Mẫu $\{\boldsymbol{\phi}^{(m)}\}$
Vai trò tiên nghiệm	Không có	(4.1)–(4.6)	(4.1)–(4.6)	(4.1)–(4.6)
Hiệp phương sai	Tiệm cận qua $[-\mathbf{H}]^{-1}$, hiệu lực có điều kiện	Đường chéo theo giả định	Đầy đủ qua $\mathbf{L}\mathbf{L}^{\top}$	Ước lượng thực nghiệm từ mẫu, đúng *nếu* hội tụ
Số tham số/chẩn đoán	d	$2d$	$d + d(d+1)/2$	$\widehat{R}$, ESS theo (4.18)
Dự báo mật độ	Cắm vào $\hat{\boldsymbol{\theta}}$	(5.6)	(5.6)	(5.6) với mẫu chuỗi
Hạn chế chính	Suy diễn tiệm cận mất hiệu lực khi nghiệm sát biên	Bỏ tương quan; đánh giá thấp bất định	Bài toán tối ưu khó, không bảo đảm cận tốt hơn	Chi phí rất cao; có thể không hội tụ trên hậu nghiệm đa đỉnh (remark 4.3)

5 Khung đánh giá ngoài mẫu

5.1 Dự báo phương sai

Với $\widehat{h}_t$ là phương sai dự báo một bước và RV_t theo (1.2), cả hai trên thang phương sai:

$$\text{MAE} = \frac{1}{N}\sum_t \left|RV_t - \widehat{h}_t\right|, \tag{5.1}$$

$$\text{RMSE} = \sqrt{\frac{1}{N}\sum_t \left(RV_t - \widehat{h}_t\right)^2}, \tag{5.2}$$

$$\text{QLIKE} = \frac{1}{N}\sum_t \left[\ln \widehat{h}_t + \frac{RV_t}{\widehat{h}_t}\right]. \tag{5.3}$$

Nhận xét 5.1 (Vì sao QLIKE là tiêu chí chính)**.** RV_t chỉ là một đại lượng *đại diện* có nhiễu cho phương sai thật, vốn không quan sát được. Theo Patton [27], QLIKE thuộc lớp hàm tổn thất *vững* đối với loại nhiễu này: Thứ hạng mô hình theo QLIKE kỳ vọng không đổi khi thay phương sai thật bằng một đại lượng đại diện không chệch. MAE và RMSE không có tính chất này (chúng có thể xếp hạng sai khi đại lượng đại diện bị nhiễu), nên được báo cáo bổ sung chứ không dùng làm căn cứ kết luận.

5.2 Dự báo mật độ

Dự báo mật độ đánh giá toàn bộ phân phối dự báo $\widehat{f}_t$, không chỉ moment bậc hai:

$$\text{NLS} = -\frac{1}{N}\sum_t \ln \widehat{f}_t(r_t). \tag{5.4}$$

NLS là một quy tắc chấm điểm chặt: Kỳ vọng của nó đạt cực tiểu khi và chỉ khi phân phối báo cáo trùng phân phối sinh dữ liệu. Đây là căn cứ để dùng NLS so sánh các mô hình khác nhau về hình dạng đuôi, điều mà QLIKE không làm được.

Cơ chế sinh $\widehat{f}_t$ khác nhau giữa hai khung suy diễn, và khác biệt này là một trong những đối tượng so sánh của phần thứ hai. Hàm hợp lý cực đại dùng ước lượng:

$$\widehat{f}_t^{\text{MLE}}(\cdot) = f\left(\cdot \mid \mathcal{F}_{t-1}; \hat{\boldsymbol{\theta}}\right), \tag{5.5}$$

bỏ qua hoàn toàn bất định của $\hat{\boldsymbol{\theta}}$. Các phương pháp biến phân tích phân trên hậu nghiệm:

$$\widehat{f}_t^{\text{VB}}(\cdot) = \int_\Theta f(\cdot \mid \mathcal{F}_{t-1}; \boldsymbol{\theta})\, p(\boldsymbol{\theta} \mid \mathcal{D}_T)\, \mathrm{d}\boldsymbol{\theta} \;\approx\; \frac{1}{S}\sum_{s=1}^{S} f\left(\cdot \mid \mathcal{F}_{t-1}; g(\boldsymbol{\phi}^{(s)})\right), \qquad \boldsymbol{\phi}^{(s)} \sim q. \tag{5.6}$$

Phân phối (5.6) là hỗn hợp của S mật độ nên có đuôi dày hơn từng thành phần. Đây là cơ chế qua đó bất định tham số đi vào dự báo, và là lý do các phương pháp Bayes có lợi thế tiềm năng ở NLS ngay cả khi không có lợi thế ở QLIKE.

5.3 Kiểm định giá trị chịu rủi ro

Gọi $I_t = \mathbf{1}\{r_t < \widehat{\mathrm{VaR}}_{t,\alpha}\}$ là chỉ báo vi phạm.

- **Kupiec** [25] kiểm định độ phủ vô điều kiện $H_0 : \mathbb{E}[I_t] = \alpha$, với thống kê $LR_{uc} \xrightarrow{d} \chi^2(1)$.
- **Christoffersen** [6] bổ sung kiểm định tính độc lập $LR_{ind} \xrightarrow{d} \chi^2(1)$ trên chuỗi $\{I_t\}$ qua mô hình Markov hai trạng thái. Thống kê độ phủ có điều kiện là $LR_{cc} = LR_{uc} + LR_{ind}$, với $LR_{cc} \xrightarrow{d} \chi^2(2)$.

6 Tổng hợp thiết kế thực nghiệm

Nghiên cứu tiến hành theo ba bước nối tiếp. Điểm cần nhấn mạnh về mặt thiết kế: *mô hình chính không được ấn định trước*. Nó là **kết quả** của Bước 1–2 chứ không phải giả định đầu vào, và chỉ mô hình thắng cuộc mới được đưa sang bước suy diễn tốn kém nhất.

Bảng 5: Ba bước của nghiên cứu: đối tượng, đại lượng thay đổi và tiêu chí

	Bước 1 — So sánh toàn bộ	**Bước 2 — Khôi phục tham số**	**Bước 3 — Suy diễn đầy đủ**
Câu hỏi	Mô hình nào và phương pháp nào cho dự báo tốt nhất?	Các bộ ước lượng có đáng tin không, và sai lệch đến từ đâu?	Hậu nghiệm đầy đủ của mô hình tốt nhất trông thế nào?
Đối tượng	Sáu mô hình một trạng thái ở Bảng 3, cùng MS-GARCH chuẩn và MS-GARCH-X Student-t (tổng cộng tám)	Mô hình chuyển trạng thái, ba kịch bản ở Bảng 7	Mô hình thắng cuộc ở Bước 1
Phương pháp	MLE, biến phân mean-field, biến phân full-rank	MLE, biến phân mean-field, biến phân full-rank	MCMC (NUTS)
Dữ liệu	VN30F1M thật	Dữ liệu mô phỏng, θ_0 đã biết	VN30F1M thật
Tiêu chí	AIC, BIC, ELBO; QLIKE, NLS, kiểm định VaR	Độ chệch, RMSE, độ phủ, Brier	$\widehat{R}$, ESS theo (4.18)

Ghi chú: Điều kiện hiệu lực xuyên suốt cả ba bước: cùng dữ liệu, cùng phân chia mẫu, cùng hàm likelihood, cùng cơ chế thu gọn Gray và cùng quy ước nhãn. Bước 2 chỉ chạy ba phương pháp đầu: chi phí một lần lặp MCMC lớn tới mức một nghiên cứu khôi phục tham số đầy đủ cho nó là bất khả thi (remark 4.3).

Nhận xét 6.1 (Vì sao MCMC đặt ở bước cuối thay vì chạy song song từ đầu)**.** Đây không phải sắp xếp cho tiện mà là hệ quả trực tiếp của chẩn đoán ở Mục 2.7. Nguyên nhân khiến MCMC thất bại trên MS-GARCH-X là *đối xứng hoán vị nhãn*, và đó là tính chất của riêng *cấu trúc chuyển trạng thái* — mô hình một trạng thái không có nhãn nào để hoán vị, nên cũng không

có cặp đỉnh soi gương nào để NUTS phải nhảy qua. Do đó, nếu mô hình thắng cuộc ở Bước 1 là một mô hình một trạng thái thì bài toán ở Bước 3 *khác về bản chất* với bài toán đã thất bại, chứ không phải cùng một bài toán chạy lại. Ngược lại, nếu mô hình thắng cuộc lại là mô hình chuyển trạng thái, kết quả và chẩn đoán đã có vẫn còn nguyên giá trị và được báo cáo như một kết quả âm có căn cứ; khi đó việc chạy lại là không cần thiết.

6.1 Các phép tương phản có kiểm soát

Danh mục mô hình ở Bảng 3 không phải một tập hợp rời rạc mà là một lưới được dựng sao cho *mỗi cặp so sánh chỉ khác đúng một yếu tố*. Nhờ đó, chênh lệch AIC/BIC trong mẫu và chênh lệch QLIKE/NLS ngoài mẫu giữa hai mô hình kề nhau quy được về một nguyên nhân duy nhất, thay vì một tổ hợp không tách được.

Bảng 6: Sáu phép tương phản và yếu tố mà mỗi phép cô lập

Cặp so sánh	**Δ tham số**	**Yếu tố được cô lập**
GARCH chuẩn → GARCH Student-t	$+1$	Đuôi dày
GARCH Student-t → GARCH-X Student-t	$+k$	Thông tin ngoại sinh
GARCH-X Student-t → MS-GARCH-X Student-t	$+8$	Cơ chế chuyển trạng thái
GARCH chuẩn → EGARCH chuẩn	$+1$	Bất đối xứng, *không* lẫn đuôi dày
GARCH Student-t → EGARCH Student-t	$+1$	Bất đối xứng, trên nền đuôi dày
GARCH-X Student-t → EGARCH-X Student-t	$+1$	Bất đối xứng, đặc tả đầy đủ

Ghi chú: $k = 2$ trong nghiên cứu này. Ba phép tương phản dưới cùng trả lời cùng một câu hỏi — bất đối xứng có đáng thêm hay không — ở ba mức nền khác nhau. Kết luận nhất quán ở cả ba mức là bằng chứng mạnh hơn nhiều so với một phép so sánh đơn lẻ; ngược lại, nếu bất đối xứng chỉ có lợi ở một mức nền, thì bản thân điều đó cũng là một phát hiện cần báo cáo chứ không phải nhiễu.

Nhận xét 6.2 (Hai họ không lồng nhau)**.** Ba mô hình GARCH ở Bảng 3 lồng nhau theo nghĩa mỗi mô hình là trường hợp riêng của mô hình sau. Quan hệ giữa *hai họ* thì khác: EGARCH không chứa GARCH như một trường hợp riêng và ngược lại — không tồn tại giá trị tham số nào đưa (2.5) về (2.3). Hệ quả: các phép tương phản giữa hai họ vẫn so sánh được bằng AIC, BIC và các tiêu chí ngoài mẫu (những đại lượng không đòi hỏi quan hệ lồng nhau), nhưng *không* được mô tả như một bậc nữa trên cùng một thang lồng nhau, và không áp dụng được kiểm định tỷ số likelihood — cùng lý do đã nêu ở remark 3.2, dù xuất phát từ một nguyên nhân khác.

Nhận xét 6.3 (Động cơ thực nghiệm của phép tương phản bất đối xứng)**.** Chuỗi lợi suất VN30F1M có hệ số bất đối xứng mẫu $-0{,}829$ (Bảng 2): phân phối lệch trái đáng kể. Đây là dấu hiệu quan sát được, phù hợp với giả thuyết hiệu ứng đòn bẩy, và là căn cứ thực nghiệm để đưa họ EGARCH vào so sánh — chứ không phải chỉ để tăng số mô hình trong bảng.

6.2 Thiết kế nghiên cứu mô phỏng khôi phục tham số

Trên dữ liệu thật, tham số sinh ra dữ liệu không quan sát được, nên không thể biết một ước lượng lệch bao nhiêu so với sự thật. Nghiên cứu mô phỏng khôi phục tham số (*parameter recovery*) giải quyết đúng khoảng trống đó: sinh dữ liệu từ một bộ tham số θ_0 *đã biết*, ước lượng lại bằng chính quy trình dùng cho dữ liệu thật, rồi đo khoảng cách giữa $\hat{\theta}$ và θ_0. Ba phương pháp được đối chiếu là hợp lý cực đại (MLE), Bayes biến phân mean-field (VB-MF) và Bayes biến phân full-rank (VB-FR).

Thiết kế hai bước. Nghiên cứu tiến hành theo trình tự thăm dò rồi xác nhận. Bước thăm dò quét tám cấu hình với số lần lặp thấp nhằm khoanh vùng những điều kiện mà các phương pháp phân kỳ nhiều nhất; kết quả bước này được báo cáo ở phụ lục như bằng chứng bổ trợ. Bước xác nhận tập trung vào *ba kịch bản trọng tâm* với $B = 100$ lần lặp Monte Carlo và $T = 2000$ quan sát mỗi mẫu (Bảng 7).

Vì sao ba kịch bản với B lớn, thay vì tám kịch bản với B nhỏ. Hai đại lượng này mua hai thứ khác nhau và không thay thế được cho nhau. Số lần lặp B mua *độ chính xác bên trong một điều kiện*: sai số chuẩn Monte Carlo của một tỷ lệ độ phủ ước lượng là $\sqrt{p(1-p)/B}$, nên với $p \approx 1/3$ nó giảm từ khoảng 12,1 điểm phần trăm ở $B = 15$ xuống còn khoảng 4,7 điểm phần trăm ở $B = 100$. Số kịch bản mua *độ phủ qua nhiều điều kiện*. Khi B nhỏ, phải dùng nhiều kịch bản một phần để bù độ nhiễu của từng ước lượng; khi $B = 100$, mỗi kịch bản đã tự cho một câu trả lời đủ chắc, nên ba kịch bản chọn đúng mang nhiều thông tin hơn tám kịch bản nhiễu.

Nguyên tắc chọn giá trị tham số. Cả ba kịch bản dùng *giá trị tham số minh họa* θ_0 đã biết trước — không phải hiệu chuẩn trực tiếp từ nghiệm ước lượng VN30F1M. Việc tách bạch tường minh giữa ”tham số minh họa dùng để kiểm tra thuật toán” và ”tham số ước lượng từ dữ liệu thật” là cần thiết: hai vai trò này không nên bị trộn lẫn khi diễn giải kết quả.

Bảng 7: Ba kịch bản trọng tâm của bước xác nhận, trên mô hình MS-GARCH-X Student-t

KB	ω_1, ω_2	α_1, α_2	β_1, β_2	ν	p_{11}, p_{22}	T	**Câu hỏi mà kịch bản trả lời**
S_1	0,05; 0,40	0,05; 0,10	0,85; 0,80	8,00	0,98; 0,95	2000	**Mốc nền.** Hai trạng thái phân biệt rõ. Bộ ước lượng có khôi phục đúng trong điều kiện thuận lợi không? Không có mốc này thì mọi kết luận ”tệ hơn” ở S_2, S_3 mất điểm tham chiếu.
S_2	0,08; 0,14	0,06; 0,08	0,85; 0,83	8,00	0,95; 0,90	2000	**Nhận dạng yếu.** Hai trạng thái gần nhau, bề mặt likelihood phẳng. Trả lời hai câu cùng lúc: vì sao các phương pháp bất đồng mạnh về p_{11}, p_{22}; và VB-MF khác VB-FR ở đâu — tương quan hậu nghiệm mà mean-field bỏ qua mạnh nhất chính ở vùng này.
S_3	0,05; 0,40	0,05; 0,10	0,85; 0,80	4,00	0,98; 0,95	2000	**Đuôi rất dày.** $\nu_0 = 4$, sát biên tồn tại phương sai. Bậc tự do có khôi phục

Tiêu chuẩn thống kê đánh giá: Với B lần lặp và tham số thật θ_0, các đại lượng đối chiếu bao gồm:

1. **Độ chệch kỳ vọng (Bias):** $\text{Bias}(\theta) = \frac{1}{B}\sum_{b=1}^{B}\left(\hat{\theta}^{(b)} - \theta_0\right)$.
2. **Sai số căn bậc hai trung bình (RMSE):** $\text{RMSE}(\theta) = \sqrt{\frac{1}{B}\sum_{b=1}^{B}\left(\hat{\theta}^{(b)} - \theta_0\right)^2}$.
3. **Độ phủ khoảng tin cậy 95% (Coverage):** Áp dụng cho hai họ phân phối Bayes biến phân (VB-MF và VB-FR):

$$\text{Coverage}(\theta) = \frac{1}{B}\sum_{b=1}^{B}\mathbf{1}\left\{\hat{\theta}^{(b)}_{2{,}5\%} \le \theta_0 \le \hat{\theta}^{(b)}_{97{,}5\%}\right\}. \tag{6.1}$$

   Giá trị lý tưởng là $0{,}95$. Độ phủ thấp hơn đáng kể phản ánh hiện tượng đánh giá thấp độ bất định hậu nghiệm do giả định độc lập cục bộ trong VB-MF.

4. **Điểm Brier phân loại trạng thái:** Đánh giá độ chính xác của xác suất lọc $\hat{\xi}_t(s)$ so với biến trạng thái thật S_t:

$$\text{Brier} = \frac{1}{T}\sum_{t=1}^{T}\sum_{s=1}^{2}\left[\hat{\xi}_t(s) - \mathbf{1}\{S_t = s\}\right]^2. \tag{6.2}$$

6.3 Khôi phục tham số cho họ EGARCH

Thiết kế ở Bảng 7 kiểm định bộ ước lượng của mô hình chuyển trạng thái — nơi việc ước lượng khó nhất và cũng là nơi sinh ra bất đồng giữa các phương pháp. Họ EGARCH cần một nghiên cứu khôi phục tham số *riêng*, vì lý do khác: đó là một bộ ước lượng mới, và tuyên bố trung tâm gắn với nó — sự tồn tại của hiệu ứng đòn bẩy — phải được kiểm định theo *cả hai chiều*.

Bảng 8: Ba kịch bản khôi phục tham số cho EGARCH-X Student-t một trạng thái

KB	θ_0	ν_0	Câu hỏi mà kịch bản trả lời
E_1	$-0{,}10$	8	**Chiều thuận.** Khi dữ liệu *có* đòn bẩy, ước lượng có phát hiện ra và khôi phục đúng độ lớn không?
E_2	0	8	**Chiều nghịch — không được bỏ.** Khi dữ liệu *không có* đòn bẩy, mô hình có *bịa ra* đòn bẩy không?
E_3	$-0{,}10$	4	**Đuôi dày.** Khôi phục còn đúng khi ν nằm sát biên tồn tại phương sai?

Ghi chú: Các tham số còn lại giữ chung ở cả ba kịch bản: $\mu_0 = 0{,}05$, $\omega_0 = 0{,}04$, $\alpha_0 = 0{,}15$, $\beta_0 = 0{,}95$, $\boldsymbol{\gamma}_0 = (0{,}05;\ 0{,}05)$, $T = 2000$, $B = 100$, burn-in $= 200$. Mức $\omega_0/(1-\beta_0) = 0{,}8$ cho phương sai vô điều kiện khoảng $2{,}2$ — cùng bậc độ lớn với phương sai mẫu của VN30F1M ($\approx 2{,}27$). Vì mô hình một trạng thái không có biến trạng thái ẩn, điểm Brier (6.2) không áp dụng ở đây; ba tiêu chí còn lại giữ nguyên.

Nhận xét 6.4 (Vì sao kịch bản E_2 là kịch bản quan trọng nhất)**.** Một nghiên cứu khôi phục tham số chỉ gồm E_1 sẽ trả lời được rằng ước lượng *tìm thấy* đòn bẩy khi đòn bẩy có thật, nhưng không

nói gì về khả năng *tìm nhầm*. Hai loại sai lầm này độc lập với nhau. Kịch bản E_2 sinh dữ liệu từ chính mô hình EGARCH nhưng với $\theta_0 = 0$: nếu ước lượng $\hat{\theta}$ vẫn lệch khỏi không một cách hệ thống, thì mọi phát biểu dạng "chuỗi VN30F1M có hiệu ứng đòn bẩy" đều mất căn cứ, vì chính quy trình ước lượng đã tạo ra kết luận đó. Đây là phép kiểm định độ đặc hiệu (*specificity*) của bộ ước lượng, và nó rẻ: chỉ cần đặt một tham số bằng không rồi chạy lại đúng quy trình.

References

[1] Baillie, R. T., Bollerslev, T., & Mikkelsen, H. O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30.

[2] Bauwens, L., Preminger, A., & Rombouts, J. V. K. (2010). Theory and inference for a Markov switching GARCH model. *Econometrics Journal*, 13(2), 218–244.

[3] Blei, D. M., Kucukelbir, A., & McAuliffe, J. D. (2017). Variational inference: A review for statisticians. *Journal of the American Statistical Association*, 112(518), 859–877.

[4] Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.

[5] Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *The Review of Economics and Statistics*, 69(3), 542–547.

[6] Christoffersen, P. F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.

[7] Davies, R. B. (1987). Hypothesis testing when a nuisance parameter is present only under the alternative. *Biometrika*, 74(1), 33–43.

[8] Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.

[9] Ding, Z., Granger, C. W. J., & Engle, R. F. (1993). A long memory property of stock market returns and a new model. *Journal of Empirical Finance*, 1(1), 83–106.

[10] Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.

[11] Engle, R. F., & Lee, G. G. J. (1999). A permanent and transitory component model of stock return volatility. In R. F. Engle & H. White (Eds.), *Cointegration, Causality, and Forecasting* (pp. 475–497). Oxford University Press.

[12] Engle, R. F., Ghysels, E., & Sohn, B. (2013). Stock market volatility and macroeconomic fundamentals. *The Review of Economics and Statistics*, 95(3), 776–797.

[13] Francq, C., & Zakoïan, J. M. (2001). Stationarity of multivariate Markov-switching ARMA models. *Journal of Econometrics*, 102(2), 339–364.

[14] Glosten, L. R., Jagannathan, R., & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *The Journal of Finance*, 48(5), 1779–1801.

[15] Gray, S. F. (1996). Modeling the conditional distribution of interest rates as a regime-switching process. *Journal of Financial Economics*, 42(1), 27–62.

[16] Haas, M., Mittnik, S., & Paolella, M. S. (2004). A new approach to Markov-switching GARCH models. *Journal of Financial Econometrics*, 2(4), 493–530.

[17] Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357–384.

[18] Hamilton, J. D., & Susmel, R. (1994). Autoregressive conditional heteroskedasticity and changes in regime. *Journal of Econometrics*, 64(1–2), 307–333.

[19] Hansen, B. E. (1992). The likelihood ratio test under nonstandard conditions: Testing the Markov switching model of GNP. *Journal of Applied Econometrics*, 7(S1), S61–S82.

[20] Hoffman, M. D., & Gelman, A. (2014). The No-U-Turn sampler: Adaptively setting path lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*, 15(1), 1593–1623.

[21] Kim, C. J. (1994). Dynamic linear models with Markov-switching. *Journal of Econometrics*, 60(1–2), 1–22.

[22] Kingma, D. P., & Welling, M. (2014). Auto-encoding variational Bayes. *International Conference on Learning Representations*.

[23] Klaassen, F. (2002). Improving GARCH volatility forecasts with regime-switching GARCH. *Empirical Economics*, 27(2), 363–394.

[24] Kucukelbir, A., Tran, D., Ranganath, R., Gelman, A., & Blei, D. M. (2017). Automatic differentiation variational inference. *Journal of Machine Learning Research*, 18(14), 1–45.

[25] Kupiec, P. H. (1995). Techniques for verifying the accuracy of risk measurement models. *The Journal of Derivatives*, 3(2), 73–84.

[26] Nelson, D. B. (1991). Conditional heteroskedasticity in asset returns: A new approach. *Econometrica*, 59(2), 347–370.

[27] Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.